



Implementación y Análisis de Tablas Hash con Datos Reales

Algoritmos y Estructuras de Datos

Autor:

Apaza Calizaya Rodrigo Josseph

Docente:

ZANABRIA GALVEZ ALDO HERNAN

Fecha:

03 de mayo de 2026

Índice

1. Introducción	2
2. Metodología	2
3. Resultados Experimentales	2
4. Análisis de Rendimiento	2
5. Conclusiones	3

1. Introducción

El presente trabajo aborda la implementación y el análisis de eficiencia de las tablas hash, una estructura fundamental para la búsqueda optimizada de información[cite: 1]. Se comparan diferentes métodos de resolución de colisiones: Encadenamiento Separado, Sondeo Lineal y Sondeo Cuadrático, utilizando un dataset de comercio real extraído de Kaggle[cite: 1, 2].

2. Metodología

Para el experimento, se cargaron 10,000 registros del dataset *Online Retail II*[cite: 2].

- **Tamaño de tabla (m):** 20,011 (número primo)[cite: 2].
- **Función Hash:** Polinomial $h(k) = \sum k_i \cdot 31^i \pmod{m}$ [cite: 2].
- **Pruebas:** Se realizaron 5 ejecuciones para promediar tiempos y colisiones[cite: 1].

3. Resultados Experimentales

Basado en las 5 ejecuciones realizadas, se obtuvieron los siguientes promedios técnicos[cite: 1, 2]:

Método	Ins. Promedio (s)	Search Promedio (s)	Colisiones
Encadenamiento	0.007909	0.000122	9,547
Sondeo Lineal	0.184567	0.006819	13,302,479
Sondeo Cuad.	0.024947	0.001961	1,139,042
Nativo (Map)	0.013743	—	N/A

Cuadro 1: Comparativa de rendimiento y colisiones.

4. Análisis de Rendimiento

El **Sondeo Lineal** presenta una deficiencia crítica debido al agrupamiento primario, resultando en más de 13 millones de colisiones[cite: 2]. El **Encadenamiento Separado** demostró ser el más rápido en este experimento, superando incluso al método nativo debido a la simplicidad de las claves manejadas[cite: 1, 2].




Figura 1: Gráfica de tiempos de inserción (datos reales).

5. Conclusiones

- El método de **encadenamiento separado** demostró ser el más eficiente en este experimento, manteniendo tiempos de inserción y búsqueda muy bajos incluso con un número considerable de colisiones. Esto confirma su robustez frente a factores de carga moderados y su buen desempeño con datos reales de tipo textual.
- El **sondeo lineal** presentó el peor rendimiento debido al fenómeno de agrupamiento primario, lo que provocó un crecimiento masivo en el número de colisiones y tiempos significativamente mayores. Esto evidencia que, aunque sencillo de implementar, no es adecuado para datasets grandes o con alta densidad.
- El **sondeo cuadrático** logró mitigar parcialmente el problema del agrupamiento, reduciendo considerablemente las colisiones en comparación con el lineal. Sin embargo, su rendimiento aún quedó por debajo del encadenamiento, mostrando que es una solución intermedia pero no óptima en este contexto.
- La **función hash polinomial** utilizada permitió una distribución relativamente uniforme de las claves, lo cual fue clave para evitar un deterioro aún mayor del rendimiento en todos los métodos evaluados.
- En términos generales, los resultados muestran que la elección del método de resolución de colisiones tiene un impacto crítico en el rendimiento de las tablas hash, especialmente cuando se trabaja con datos reales. Para aplicaciones prácticas, el encadenamiento separado se perfila como la opción más confiable y escalable bajo condiciones similares a las evaluadas.

Referencias

- [1] T. H. Cormen, C. E. Leiserson, R. L. Rivest, y C. Stein, *Introduction to Algorithms*, 3ra ed. Cambridge, MA, USA: MIT Press, 2009[cite: 2].
- [2] R. Sedgewick y K. Wayne, *Algorithms*, 4ta ed. Upper Saddle River, NJ, USA: Addison-Wesley, 2011[cite: 1].
- [3] UCI Machine Learning, *Online Retail II Data Set*. Disponible en: <https://archive.ics.uci.edu/ml/datasets/Online+Retail+II>[cite: 2].